

Речь на защиту проекта

Команда 1 · Country Data · «Кому помогать» · YDL 2026, Неделя 2, День 3 · регламент 10 минут · фокус — Шаг 5 (Классификация)

Как читать этот документ

Значком □ отмечены фразы, которые можно говорить вслух почти дословно. Курсивом — заметки докладчику (что показать на экране, чего не говорить). Один ноутбук на команду, выступаем по очереди — у каждого свой блок. Главный акцент защиты — Шаг 5: именно классификатор доказывает, что наши группы реальные, а не «разноцветные точки».

0. Вступление — кто говорит первым (~30 сек)

Спикер 1 — постановка задачи

□ «Нам выдали 167 стран и 9 показателей — доход, ВВП на душу, детская смертность, продолжительность жизни и другие. Готовой метки нет: никто не сказал, какие страны “бедные”, а какие “развитые”. Мы — аналитики гуманитарного фонда, и наша задача: найти эти группы сами, превратить их в метку и честно проверить, можно ли её предсказывать. Главный вопрос защиты — в самом конце, на Шаге 5: а метка вообще не случайна?»

Это и есть три опорные мысли задания: (1) данные и находка EDA, (2) сколько кластеров и как называли, (3) насколько хорошо классификатор предсказывает метку и наш честный вердикт.

Опорная мысль 1 — Данные и находка EDA (~1 мин)

Спикер 1 (или 2)

□ «167 стран, 9 числовых признаков, пропусков нет. Но масштабы несопоставимы: доход — десятки тысяч, рождаемость и инфляция — единицы. Поэтому перед KMeans и PCA мы обязательно привели всё к одному масштабу через StandardScaler — иначе доход и ВВП перекидали бы остальные семь признаков.»

□ «Находка, которая нас удивила: детская смертность почти зеркально связана с рождаемостью ($r \approx +0.85$) и с продолжительностью жизни ($r \approx -0.89$). То есть это не девять независимых признаков, а две-три “оси” — богатство и здоровье. Это сразу подсказало: кластеров будет немного, а PCA сожмёт данные почти без потерь.»

На экране: матрица корреляций (Шаг 1.7) и итоги Шага 1.

Опорная мысль 2 — Сколько кластеров, как называли, вид на PCA (~1.5 мин)

Спикер 2

□ «Меток нет — число кластеров мы не угадывали. Построили метод локтя и коэффициент силуэта для k от 2 до 10. Локоть чётко загибается на $k = 3$. Силуэт при этом почти плоский ($\approx 0.28-0.30$) — и это мы говорим честно: значит, группы слегка перетекают, резких “островов” нет. Первому k не поверили, проверили соседние: $k = 2$ — слишком грубо, $k = 4-5$ дают мизерный прирост силуэта и дробят группы без нового смысла. Поэтому $k = 3$ — осознанный выбор в пользу смысла, а не погоня за третьим знаком метрики.»

□ «Кластеры мы назвали по их профилю, а не номерами: “Низкий доход, высокая смертность и рождаемость” (47 стран — это наши “нуждающиеся”), “Средний доход” (84 страны) и “Высокий доход, низкая детская смертность” (36 стран).»

Спикер 3 — PCA

□ «Чтобы увидеть 9 признаков глазами, мы сжали их в две главные компоненты. Они удерживают 63.1% дисперсии. На проекции группы выстроились полосами по PC1: бедные → средние → богатые. Крайние группы отделяются чётко, а граница “средние ↔ богатые” слегка размыта — запомните это место, оно всплывёт на Шаг 5.»

На экране: графики локтя/силуэта (2.2) и проекция PCA с раскраской по кластерам (4.2).

★ Опорная мысль 3 — ШАГ 5. КЛАССИФИКАЦИЯ (главный блок, ~4 мин)

Спикер 4 — это кульминация защиты, говорим подробно и уверенно

а) Зачем вообще этот шаг

□ «Кластеры мы придумали сами. Возникает честный вопрос: а вдруг это просто разноцветные точки, а не настоящие группы? Шаг 5 отвечает на него строго. Логика такая: если группы реальные и разделимые, то классификатор, обученный с нуля по исходным признакам, должен уверенно угадывать нашу метку. Если же метрики низкие — мы честно признаем, что кластеризация дала размытые группы. Это и есть принцип дня: не верь, проверь.»

б) Как проверяли — без утечки данных

□ «Мы разбили 167 стран на train (116) и test (51) стратифицированно — классы разного размера, и мы сохранили их пропорции в тесте. Очень важная деталь: StandardScaler мы положили внутрь Pipeline, чтобы он обучался только на train. Иначе информация из теста просочилась бы в обучение, и метрики были бы нечестными. Обучили две базовые модели — логистическую регрессию и KNN — и посчитали accuracy, precision, recall, F1. А поскольку выборка маленькая, добавили ещё 5-fold кросс-валидацию.»

в) Результаты — честно train и test

Лучшая модель — логистическая регрессия. Ключевые числа:

Метрика (test, 51 страна)	Значение	Что значит
Accuracy	0.922	92% стран теста отнесены в верную группу
Precision (macro)	0.927	когда модель называет группу — она почти всегда права
Recall (macro)	0.896	почти всех представителей группы находит
F1 (macro)	0.909	баланс precision и recall — высокий
F1 на 5-fold CV	0.93-0.96	на разных разбиениях результат устойчив

□ «Обе модели предсказывают метку уверенно: accuracy $\approx$ 0.90-0.92, F1 $\approx$ 0.87-0.91, а на кросс-валидации F1 поднимается до 0.93-0.96. Разрыв train-test

небольшой — модель не переобучилась. Вывод прямой: классификатор легко выучивает границы между группами по исходным признакам, значит группы реальны и разделимы.»

г) Где модель ошибается — и почему это нас радует

□ «Самое интересное — куда уходят ошибки. Беднейший класс — “низкий доход, высокая смертность” — распознаётся идеально: precision и recall = 1.000. Это наше плотное, надёжное ядро — те самые страны, которым нужна помощь, и в них модель не ошибается ни разу. А все ошибки сосредоточены на границе “средние ↔ богатые” — ровно там, где и PCA показал размытость. То есть три независимых метода — профиль признаков, геометрия PCA и классификатор — указывают на одну и ту же зыбкую границу. Это не противоречие, а согласованность: данные честно говорят, где деление чёткое, а где условное.»

На экране: `classification_report` (5.2) и матрица ошибок — показать нулевые ошибки в беднейшем классе и путаницу средние/богатые.

Честный вердикт команды (~1 мин)

Спикер 4 или капитан команды

□ «Наш вердикт: структура данных подтвердилась. Деление стран на бедные / средние / богатые, которое мы сконструировали кластеризацией, подтверждается тремя независимыми способами: интерпретируемым профилем признаков (Шаг 3), геометрией PCA — 63% дисперсии (Шаг 4) и обучаемостью классификатора — $F1 \approx 0.91$ (Шаг 5). Это не разноцветные точки, а реальные группы. Единственное честное “но”: граница между средними и богатыми странами размыта — и мы это видим во всех трёх проверках, а не прячем.»

□ «Практический итог для фонда: группа “низкий доход, высокая смертность” — 47 стран — это надёжно очерченный список тех, кому помощь нужна в первую очередь.»

Подготовка к вопросам (5 минут Q&A;)

В: Почему метку предсказывать «легко» — это не жульничество?

О: Метку задал KMeans по масштабированным признакам, а классификатор учится с нуля на исходных признаках и проверяется на отложенном test. Высокая точность означает, что группы геометрически разделимы, а не что мы «подсмотрели ответ».

В: Не переобучились ли вы? Выборка всего 167 стран.

О: Разрыв train-test небольшой, а 5-fold кросс-валидация даёт стабильный $F1$ 0.93–0.96 — на разных разбиениях результат держится. Поэтому уверенно, а не случайно.

В: Почему именно логистическая регрессия, а не сложная модель?

О: Задача — проверить разделимость, а не выжать максимум. Простая модель честнее: если уже линейные границы дают $F1$ 0.91, значит группы реально разделимы. KNN дал близкий результат — вывод не зависит от выбора модели.

В: Почему точность не 100%?

О: Ошибки сидят на границе «средние ↔ богатые» — той же, что размыта на PCA. Это свойство данных, а не баг: переход между средним и высоким развитием действительно плавный.

В: Зачем StandardScaler внутри Pipeline?

О: Чтобы scaler обучался только на train. Если масштабировать до сплита, статистика теста утечёт в обучение и метрики будут завышены.

Тайминг (10 минут)

Блок	Время	Спикер
Вступление + задача	0:30	1
Данные + находка EDA	1:00	1-2
Кластеры + PCA	1:30	2-3
★ Классификация (Шаг 5)	4:00	4
Вердикт + список фонда	1:00	капитан
Резерв / переходы	2:00	—

Источник данных: Kaggle — rohan0301/unsupervised-learning-on-country-data (167 стран, 9 признаков). Все числа взяты из team_task.ipynb.